

ÉVALUATION DE COMPATIBILITÉ

Infrastructure Hybride InduTechData

Intégration Cloud AWS + Redpanda avec Environnement SI ON-Premise

Document préparé pour :

InduTechData – Entreprise fictive spécialisée en analyse de données pour le secteur industriel.

Date :

Juin 2026

Contexte de la mission :

Ce document présente une évaluation complète de la compatibilité d'une architecture hybride proposé pour InduTechData. L'infrastructure doit moderniser la gestion des données tout en garantissant l'interopérabilité avec les systèmes existants et en respectant les contraintes de sécurité, de performance et de coûts.

SOMMAIRE

- 1. Justification des composants clouds sélectionnés
- 2. Évaluation de la sécurité et conformité
- 3. Analyse de l'interopérabilité
- 4. Scalabilité et gestion des coûts
- 5. Estimation des coûts – Année 1
- 6. Points de vigilance et recommandations
- 7. Conclusion

1. Justification des composants clouds sélectionnés

Besoins spécifiques d'InduTechData :

Traitement de 50 Go/mois de données en temps réel provenant d'objets connectés (**IoT**), maintenance de 40 To de données critiques, et scalabilité pour la croissance future.

Description du SI on-premise de InduTechData:

- Un cluster de serveurs SQL Server hébergeant 40 To de données critiques. Ces bases contiennent les données des applications métiers telles que l'ERP et le CRM, avec des sauvegardes régulières et une réplication pour la résilience.
- Une baie de stockage SAN (Storage Area Network) pour les données non structurées (10 To), principalement issues des journaux système, des fichiers utilisateurs et des capteurs IoT.
- Un serveur Active Directory (AD) pour l'authentification, l'autorisation et la gestion des utilisateurs.
- Des serveurs dédiés à un ERP et à un CRM, assurant la gestion des processus internes tels que la comptabilité, les ressources humaines, et la relation client.

Sélection des composants clouds

1. Stockage de données non structurées →

- **Amazon S3** (Simple Storage Service)

Les 50 Go/mois de données IoT + les 10 To existants de la baie SAN peuvent migrer progressivement sans planification de capacité. On peut définir des *lifecycle policies* pour archiver automatiquement vers S3 Glacier les données froides (logs anciens, fichiers utilisateurs archivés).

Chiffrement natif au repos (SSE-S3 ou SSE-KMS), chiffrement en transit (TLS), politiques IAM granulaires, et intégration avec AWS PrivateLink pour que les flux ne transitent jamais par l'internet public.

Interopérabilité avec Redpanda : Redpanda intègre nativement un connecteur **Tiered Storage** pour l'archivage vers S3. Les segments de topics Kafka/Redpanda (logs IoT, journaux système) peuvent être déversés automatiquement dans S3 en tant que stockage de longue durée, sans pipeline supplémentaire. Les consommateurs en aval peuvent lire directement depuis S3.

Alternatives rejetées : Azure Blob / Google cloud storage – AWS maîtrise mieux Redpanda et avantage tarif S3.

2. Data Warehouse →

– Amazon Redshift

Redshift est un entrepôt de données colonnaire, optimisé pour les requêtes SQL analytiques complexes (agrégations, jointures larges) que les équipes d'InduTechData utilisent pour analyser les données industrielles.

Redshift **Spectrum** permet d'interroger directement les données brutes dans S3 sans les charger, utile pour les requêtes *ad hoc* sur des archives.

Alternatives rejetées : Snowflake / BigQuery – Redshift avantage du coût total de possession cloud (TCO) sur la durée et gestion plus simple du cluster.

3. Synchronisation avec SQL Server on-premise →

– AWS DMS (Data Migration Service)

Ce service permet une réplication continue (CDC – *Change Data Capture*) depuis SQL Server vers Redshift. Les 40 To existants sont migrés en charge initiale (*full load*), puis les changements sont répliqués en quasi-temps réel.

Alternatives rejetées : Talend, coût de licence important.

4. Streaming en temps réel →

– Redpanda

Redpanda est le hub central du streaming. Il reçoit les flux des capteurs IoT, alimente Redshift pour l'analytique et S3 pour l'archivage.

Il est 100% compatible avec l'API Kafka. Tous les connecteurs, clients et outils de l'écosystème Kafka fonctionnent sans modification. Cela réduit la courbe d'apprentissage et facilite l'intégration avec les outils existants d'InduTechData.

Redpanda est écrit en C++ (vs Java pour Kafka), ce qui se traduit par une latence plus faible, une consommation mémoire réduite et un déploiement simplifié (un seul binaire, pas de dépendance ZooKeeper). C'est particulièrement pertinent pour les flux IoT qui exigent un traitement fiable et rapide.

Redpanda peut décharger automatiquement les données des topics vers S3, garantissant la rétention à long terme sans surcharger les brokers.

Alternatives rejetées : Apache Kafka – Redpanda meilleur en latence/ressources.

5. Sécurisation et gestion des identités →

– AWS Directory Service (AD Connector)

AD Connector agit comme un proxy : il redirige les requêtes d'authentification des services AWS vers l'Active Directory on-premise, sans dupliquer les annuaires. Les utilisateurs continuent de s'authentifier avec leurs identifiants d'entreprise pour accéder aux services cloud (Console AWS, Redshift, EC2, etc.).


En combinant AD Connector avec IAM Identity Center, on obtient un portail SSO unique. Les groupes AD existants sont mappés sur des rôles IAM, ce qui évite de gérer deux référentiels de droits distincts.

Redpanda supporte SASL/SCRAM et mTLS. Les comptes de service utilisés par les producteurs/consommateurs Redpanda peuvent être gérés dans l'AD et authentifiés via IAM, garantissant une traçabilité des accès de bout en bout.

L'ensemble repose sur une liaison AWS Direct Connect ou VPN Site-to-Site entre le datacenter et le VPC AWS, pour que les flux d'authentification et de données ne transitent jamais en clair sur l'internet public.

Alternatives rejetées : Microsoft AD, coûts plus élevés.

Schéma Logique des Composants



2. Évaluation de la Sécurité et Conformité

InduTechData manipule des données critiques (ERP, CRM, données industrielles sensibles). L'architecture proposée doit garantir protection, confidentialité et traçabilité.

Protection des flux de données

L'architecture retenue assure la protection des données lors de leur transfert entre le SI on-premise et les services cloud AWS.

Les échanges entre le datacenter d'InduTechData et AWS transitent via une liaison sécurisée AWS Direct Connect. Cette connectivité permet de limiter l'exposition des flux aux réseaux publics et garantit un chiffrement des communications.

Redpanda supporte nativement les protocoles TLS et mTLS (Mutual TLS) pour sécuriser les communications entre producteurs, consommateurs et brokers. Les flux IoT et les journaux système peuvent ainsi être transmis de manière chiffrée.

Les services AWS retenus utilisent également le chiffrement TLS pour les communications :

- AWS DMS lors des répliquions SQL Server → Redshift ;
- Amazon S3 lors du stockage et des transferts de données ;
- Amazon Redshift pour les connexions analytiques ;
- AD Connector et IAM Identity Center pour les mécanismes d'authentification.

L'ensemble de la chaîne de traitement respecte donc les bonnes pratiques de sécurisation des flux sensibles.

Gestion des identités et contrôle d'accès

La gestion des identités reste centralisée autour de l'Active Directory déjà présent dans le SI on-premise.

L'utilisation d'AD Connector permet aux services AWS de déléguer l'authentification à l'Active Directory existant sans nécessiter de duplication des comptes utilisateurs.

L'intégration avec IAM Identity Center fournit un mécanisme de Single Sign-On (SSO) permettant aux utilisateurs d'accéder aux ressources cloud avec leurs identifiants habituels.

Cette approche présente plusieurs avantages :

- conservation du référentiel d'identités existant ;
- gestion unifiée des droits ;
- simplification de l'administration ;
- meilleure traçabilité des accès.

L'architecture assure ainsi une cohérence entre les mécanismes d'authentification on-premise et cloud.

3. Analyse de l'interopérabilité

Intégration de Redpanda avec le SI existant

Redpanda repose sur l'API Kafka, devenue un standard de facto dans le domaine du streaming de données.

Cette compatibilité permet l'intégration avec de nombreux outils et connecteurs déjà disponibles sur le marché sans développement spécifique.

Dans l'architecture proposée, Redpanda joue le rôle de plateforme centrale de streaming pour :

- les données issues des capteurs IoT ;
- les journaux système ;
- les événements applicatifs pouvant être générés par les applications métier.

Les données peuvent être acheminées en temps réel vers les services cloud tout en restant compatibles avec les outils analytiques existants.

Intégration avec SQL Server

L'intégration avec SQL Server est assurée par AWS DMS.

Le mécanisme CDC (Change Data Capture) permet de détecter automatiquement les modifications réalisées dans les bases SQL Server et de les répliquer vers Amazon Redshift sans interruption des applications ERP et CRM.

Cette approche présente plusieurs avantages :

- faible impact sur les performances du SI existant ;
- synchronisation quasi temps réel ;
- réduction des traitements manuels d'export/import ;
- conservation des applications métiers existantes.

Automatisation des flux de données

L'ensemble des flux retenus peut être automatisé :

Flux	Automatisation
SQL Server → DMS → Redshift	CDC automatique
Redpanda → Amazon S3	Tiered Storage automatique
AD → AD Connector → IAM Identity Center	Synchronisation continue
Flux IoT → Redpanda	Streaming temps réel

L'architecture limite ainsi les opérations manuelles et améliore la fiabilité des échanges de données.

4. Scalabilité et gestion des coûts

Réponse aux besoins futurs

Les besoins actuels d'InduTechData représentent :

- 40 To de données critiques ;
- 10 To de données non structurées ;
- 50 Go/mois de données IoT.

Les services retenus offrent une capacité d'évolution adaptée à une croissance progressive.

Amazon S3 fournit une capacité de stockage pratiquement illimitée. L'augmentation du volume des logs, fichiers utilisateurs ou données IoT ne nécessite aucune modification d'infrastructure.

Redshift permet d'augmenter les capacités de calcul et de stockage selon les besoins analytiques futurs de l'entreprise.

Redpanda est conçu pour absorber des volumes croissants de messages et de flux temps réel avec une faible latence.

L'augmentation du nombre de capteurs IoT ou de la fréquence des remontées de données peut être prise en charge sans modification majeure de l'architecture.

Recommandations de surveillance des coûts

Afin d'éviter les dérives budgétaires, plusieurs outils AWS peuvent être activés :

AWS CloudWatch

Permet de surveiller :

- l'utilisation de Redshift ;
- l'activité DMS ;
- la consommation des ressources ;
- les performances globales.

AWS Budgets

Permet :

- la définition de seuils budgétaires ;
- l'envoi d'alertes automatiques ;
- le suivi mensuel des dépenses.

AWS Cost Explorer

Permet :

- l'analyse détaillée des coûts ;
- l'identification des services les plus consommateurs ;
- l'optimisation continue des ressources.

5. Première estimation des coûts

Estimation basée sur les tarifs publics AWS et Redpanda disponibles au moment de l'étude. Les coûts réels dépendront du dimensionnement final, des volumes de données, du trafic réseau et du niveau de service retenu.

Composant	Coût initial	Coût mensuel estimé	Méthode d'estimation
Amazon S3	0 €	220 à 260 €	Basée sur 10 To stockés
Amazon Redshift	0 €	400 € à 800 €	Basée sur un cluster analytique de taille moyenne
AWS DMS	0 €	100 à 250 €	Réplication CDC continue
AD Connector	0 €	30 à 60 €	Tarif AWS standard
IAM Identity Center	Inclus AWS	Inclus	
Redpanda Cloud	0 €	300 à 800 €	Estimation selon une charge IoT modérée
Direct Connect	500 à 2 000 €	200 à 500 €	Tarif AWS standard

Estimation globale

- Mise en œuvre : ~500 à 2 000 €
- Exploitation : ~1 300 à 2 700 €/mois

Les coûts présentés sont des estimations indicatives destinées à évaluer la faisabilité financière de la solution. Une étude de dimensionnement détaillée et l'utilisation du calculateur AWS seraient nécessaires avant tout déploiement réel.

7. Conclusion

L'architecture hybride proposée est compatible avec l'environnement existant d'InduTechData. Elle conserve les systèmes métiers actuels (ERP, CRM, SQL Server et Active Directory) tout en apportant des capacités modernes de streaming, d'analyse et de stockage cloud. Les mécanismes de sécurité, d'authentification et de synchronisation répondent aux exigences de protection des données, tandis que l'utilisation de services managés AWS garantit une bonne évolutivité et une maîtrise raisonnable des coûts.